

神经网络和深度学习（类脑）Week 3 作业

姓名: 王冰怡 学号:21210850015

2021 年 10 月 18 日

题目 1. 一、某地成年人肥胖者 (A_1) 占 10%, 中等者 (A_2) 占 82%, 瘦小者 (A_3) 占 8%, 又肥胖者, 中等者, 瘦小者高血压病的概率分别为 20%,10%,5%.

(1). 求该地成年人患高血压的概率.

(2). 若知某人患高血压, 他最可能属于哪种体型?

解答. 设事件 A_1, A_2, A_3 分别某地成年人为肥胖者、中等者、瘦小者; 为设事件 B 为某地成年人患有高血压病。

则 $P(A_1) = 0.1, P(A_2) = 0.82, P(A_3) = 0.08, P(B|A_1) = 0.2, P(B|A_2) = 0.1, P(B|A_3) = 0.05$

(1). 由全概率公式

$$\begin{aligned} P(B) &= \sum_{i=1}^3 P(A_i)P(B|A_i) \\ &= 0.1 * 0.2 + 0.82 * 0.1 + 0.08 * 0.05 \\ &= 10.6\% \end{aligned}$$

(2). 由贝叶斯公式

$$P(A_1|B) = \frac{P(A_1)P(B|A_1)}{\sum_{i=1}^3 P(A_i)P(B|A_i)} \approx 18.87\%$$

$$P(A_2|B) = \frac{P(A_2)P(B|A_2)}{\sum_{i=1}^3 P(A_i)P(B|A_i)} \approx 77.36\%$$

$$P(A_3|B) = \frac{P(A_3)P(B|A_3)}{\sum_{i=1}^3 P(A_i)P(B|A_i)} \approx 3.77\%$$

这个人最有可能是中等体型的人。

题目 2. 如教材 3.54 式和 3.56 式，分别写出如下有向图和无向图对应的概率分布.




图1 有向图




图2 无向图

解答. (1) 通过看图，先找出所有节点的父节点:

$$Pa\mathcal{G}(a) = \{\}$$

$$Pa\mathcal{G}(b) = \{a\}$$

$$Pa\mathcal{G}(c) = \{a\}$$

$$Pa\mathcal{G}(d) = \{b\}$$

$$Pa\mathcal{G}(e) = \{c\}$$

$$Pa\mathcal{G}(f) = \{c, b\}$$

$$Pa\mathcal{G}(g) = \{d\}$$

$$Pa\mathcal{G}(h) = \{e, f, g\}$$

$$Pa\mathcal{G}(i) = \{e\}$$

$$\text{则 } P(\mathbf{x}) = \prod_i p(x_i | Pa\mathcal{G}(x_i))$$

$$= p(a)p(b|a)p(c|a)p(d|b)p(e|c)p(f|c, b)p(g|d)p(h|e, f, g)p(i|e)$$

(2) 通过观察无向图图的连通性，可以划分为 11 个团，正好对应于每条边的两个节点为一个团。

$$p(a, b, c, d, e, f, g, h, i) = \frac{1}{Z} \phi^{(1)}(a, b) \phi^{(2)}(a, c) \phi^{(3)}(b, d) \phi^{(4)}(c, e) \\ \phi^{(5)}(c, f) \phi^{(6)}(d, g) \phi^{(7)}(e, i) \phi^{(8)}(e, h) \phi^{(9)}(e, h) \phi^{(10)}(e, h) \phi^{(11)}(e, h)$$

其中归一化常数 Z 被定义为 ϕ 函数乘积的所有状态的求和或积分。

题目 3. 取值为 0,1,2,3,4,5 的概率分别为 1/2,1/4,1/8,1/16,1/32,1/32。求其香农熵。


解答. 设 X 取值为 $0,1,2,3,4,5$ 的概率分别为 $1/2,1/4,1/8,1/16,1/32,1/32$.

$$\begin{aligned} H(x) &= \mathbb{E}_{X \sim P}[I(x)] = -\mathbb{E}_{X \sim P}[\log P(x)] \\ &= -\sum_{i=1}^6 P(X = x_i) \log P(X = x_i) \\ &= \frac{1}{2} \log 2 + \frac{1}{4} \log 4 + \frac{1}{8} \log 8 + \frac{1}{16} \log 16 + 2 * \frac{1}{32} \log 32 \\ &= \frac{31}{16} \log 2 \end{aligned}$$


题目 4. 叙述 KL 散度和交叉熵定义，并给出自己的理解

解答. 我并非数学专业，对于数学公式没有直观的感觉，只能通过例子去体会数学公式

首先从熵开始，第一次接触熵的概念，是在高中化学课上，化学老师表达的意思是，如果分子无序分布，则熵高；如果分子有序地分布在某一边，则熵低。



无序分布，熵高



相对有序分布，熵低

熵大概表示着混乱程度，不确定程度，和决策困难度？

熵的定义：

$$H(X) = -\sum_{i=1}^n p(x_i) \log p(x_i)$$



在逛大学路的时候，看到美人蹄和 1 串成名两家店，两家店门口人数差不多。小王打算从其中一家店买点东西，但是他很纠结，假设他选中每一家店的概率都是 0.5。

表 1: 夜宵种类选择概率.

x	$p(x)$
美人蹄	0.5
1 串成名	0.5

根据熵的计算公式得出： $H(X) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{2}\log_2\frac{1}{2} = 1$
这里计算熵我们都用 2 位底数。

再看看饮品店：



桂花茶和炒酸奶前的人群分布显然不一样，我们假设小王选择桂花茶和炒酸奶的概率分别为 0.1 和 0.9

表 2: 饮料种类选择概率.

x	p(x)
桂源铺	0.1
又炒酸奶	0.9

根据熵的计算公式得出： $H(X) = -\frac{1}{10}\log_2\frac{1}{10} - \frac{9}{10}\log_2\frac{9}{10} \approx 0.1954$

跟夜宵计算出来的熵相比，决定夜宵吃什么比决定冷饮喝什么，更纠结。看看上述两组店铺的人群的分布，像不像最开始描述的分子分布一样。

对于离散随机变量，如果概率密度是由一个 1 和若干个 0 组成，如

表 3: 离散型随机变量的特殊情况.

x	p(x)
1	1
2	0
\vdots	\vdots
n	0

根据熵的计算公式 $H(X) = 1\log 1 + 0\log 0 + \cdots + 0\log 0 = 0$ 。得到熵等于 0. 这算是一个比较重要的特点。

然后看看 KL 散度，KL 散度表示着 P 和 Q 分布的不对称性。是一种量化两种概率分布 P 和 Q 之间差异的方式

$$D_{KL}(p||q) = \sum_{i=1}^n p(x_i) \log\left(\frac{p(x_i)}{q(x_i)}\right)$$

表 4: 分布不对称的一个例子.

x	p(x)	q(x)
1	0.1	0.9
2	0.9	0.1

根据熵的计算公式有 $-\sum_{i=1}^n p(x_i) \log p(x_i) = -\sum_{i=1}^n q(x_i) \log q(x_i)$ 熵是相等的。

$$D_{KL}(p||q) = 0.1[\log_2 0.1 - \log_2 0.9] + 0.9(\log_2 0.9 - \log_2 0.1) \approx 2.536$$

KL 散度有一个特殊的情况，如果在某些取值上，p 有分布，而 q 没有分布，则 KL 散度会变成正无穷。

表 5: 分布不对称的一个例子.

x	p(x)	q(x)
1	0.5	1
2	0.5	0

$$D_{KL}(p||q) = 0.5\log(\frac{0.5}{1}) + 0.5\log(\frac{0.5}{0}) = +\infty$$

$$D_{KL}(p||q) = 1 * \log_2(\frac{1}{0.5}) + 0 * \log(\frac{0}{0.5}) = 1$$

$$\text{其中 } \lim_{x \rightarrow 0^+} x \log x = 0$$

KL 散度表示着用 Q 分布描述 P 分布需要增加的字节数。

表 6: KL 散度表示编码位数差的一个例子.

天气	地区 1 的概率 p(x)	地区 1 的编码	地区 2 的概率 q(x)
晴天	$\frac{1}{2}$	1	$\frac{1}{8}$
多云	$\frac{1}{4}$	01	$\frac{1}{8}$
小雨	$\frac{1}{8}$	011	$\frac{1}{4}$
大雨	$\frac{1}{8}$	010	$\frac{1}{2}$

$$D_{KL}(p||q) = \frac{1}{2}\log_2\frac{\frac{1}{2}}{\frac{1}{8}} + \frac{1}{4}\log_2\frac{\frac{1}{4}}{\frac{1}{8}} + \frac{1}{8}\log_2\frac{\frac{1}{8}}{\frac{1}{4}} + \frac{1}{8}\log_2\frac{\frac{1}{8}}{\frac{1}{2}} = \frac{7}{8}$$

$$H(P) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{4}\log_2\frac{1}{4} - \frac{1}{8}\log_2\frac{1}{8} - \frac{1}{8}\log_2\frac{1}{8} = \frac{14}{8}$$

$E(\text{用地区 1 的编码编码地区 1 的天气用的编码位数}) =$

$$\frac{1}{2} * 1 + \frac{1}{4} * 2 + \frac{1}{8} * 8 + \frac{1}{8} * 3 = \frac{14}{8}$$

$E(\text{用地区 1 的编码编码地区 2 的天气用的编码位数}) =$

$$\frac{1}{8} * 1 + \frac{1}{8} * 2 + \frac{1}{4} * 3 + \frac{1}{2} * 3 = \frac{21}{8}$$

所以在这个例子中：

$$H(P) = E(\text{用地区 1 的编码编码地区 1 的天气用的编码位数})$$

$$E(\text{用地区 1 的编码编码地区 1 的天气用的编码位数}) =$$

$$E(\text{用地区 1 的编码编码地区 2 的天气用的编码位数}) - D_{KL}(p||q)$$

$$D_{KL}(p||q) = H(p, q) - H(p)$$

当 $H(p) = 0$ 时， $D_{KL}(p||q) = H(p, q)$ 。因此在机器学习的分类任务领域中，让 p 表示真实分布的标签，比如猫狗分类，手写体数字识别。真实的标签由一个 1 和若干个 0 组成，因此 $H(p) = 0$ 。所以在机器学习领域，交叉熵等于 KL 散度。

题目 5. 机器学习初识：学习 sklearn 中的朴素贝叶斯

Sklearn 为我们提供了这几种朴素贝叶斯的分类器：

`naive_bayes.GaussianNB`

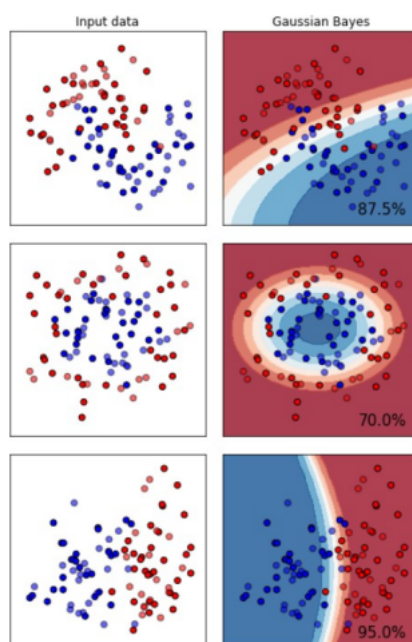
`naive_bayes.BernoulliNB`

`naive_bayes.MultinomialNB`

`naive_bayes.ComplementNB`

1. 说明每种分类器的含义以及区别
2. 利用 sklearn 自带的数据集：(from sklearn.datasets import make_moons, make_circles, make_classification), 自行划分训练集和测试集 (无需验证集), 使用第一种分类器 (`naive_bayes.GaussianNB`), 并且可视化结果, 说明在不同数据类型下分类器效果的差别。

举例效果如下：



解答. 1. 这四种模型的选择主要取决于输入数据的类型。

`naive_bayes.GaussianNB`, 如果参数是连续值, 而且越接近正态分布越好。

`naive_bayes.BernoulliNB`, 适用于参数都是二值变量, 如果不是二值变量, 可以先对变量二值化

`naive_bayes.MultinomialNB`, 特征变量是离散数据, 而且符合多项分布。适合处理文本数据, 而且输入参数不能是负数。

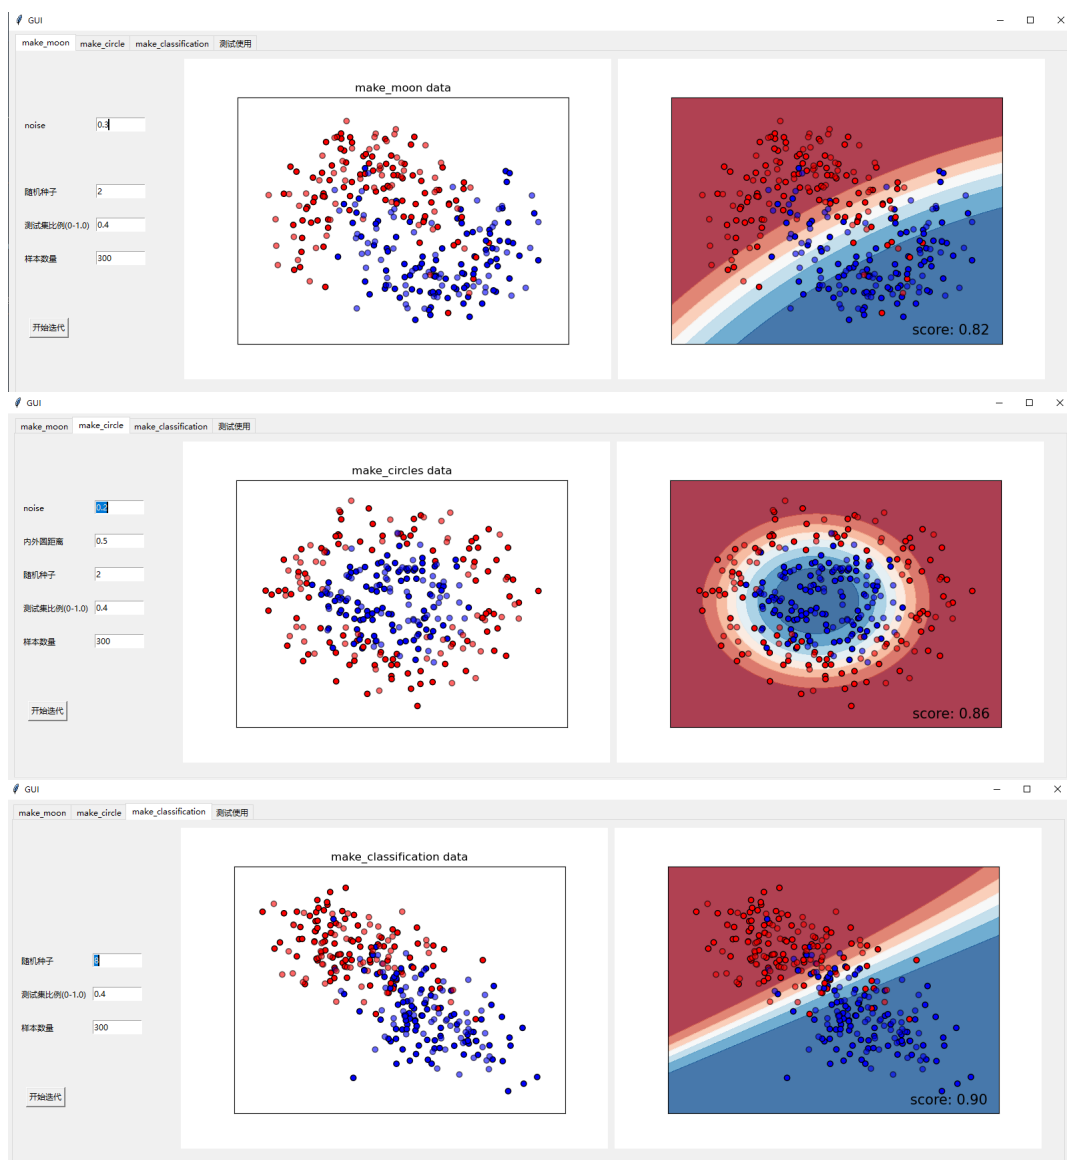
和 `naive_bayes.ComplementNB` 是 `MultinomialNB` 模型的一个变种, 实现了补码朴素贝叶斯 (CNB) 算法。CNB 是标准多项式朴素贝叶斯 (MNB) 算法的一种改进, 比较适用于不平衡的数据集, 在文本分类上的结果通常比 `MultinomialNB` 模型好。

2.

从结果上来看, 并不是想象中拟合出两个山峰一样的概率密度, 首先这个决策边界的形状, 是由两个不相关的正态分布组成, 可以是椭圆形, 可以是“X”型, 或者说椭圆很大, 以至于显示的部分看起来像一个直线。显然在 `make_circles` 数据集里面拟合的最好, 但是如果内外圆距离太近, 就会过拟合, 样本多一些就没事了。

以 `make_moon` 数据为例, 在上图看到接近直线的决策边界, 其实是一个大椭圆的一部分。这个大椭圆就是二维正态分布峰值部分。

应用不同的数据集, 能看到决策边界可能是“X”型, 这说明两个正态分布可能是一正一负。



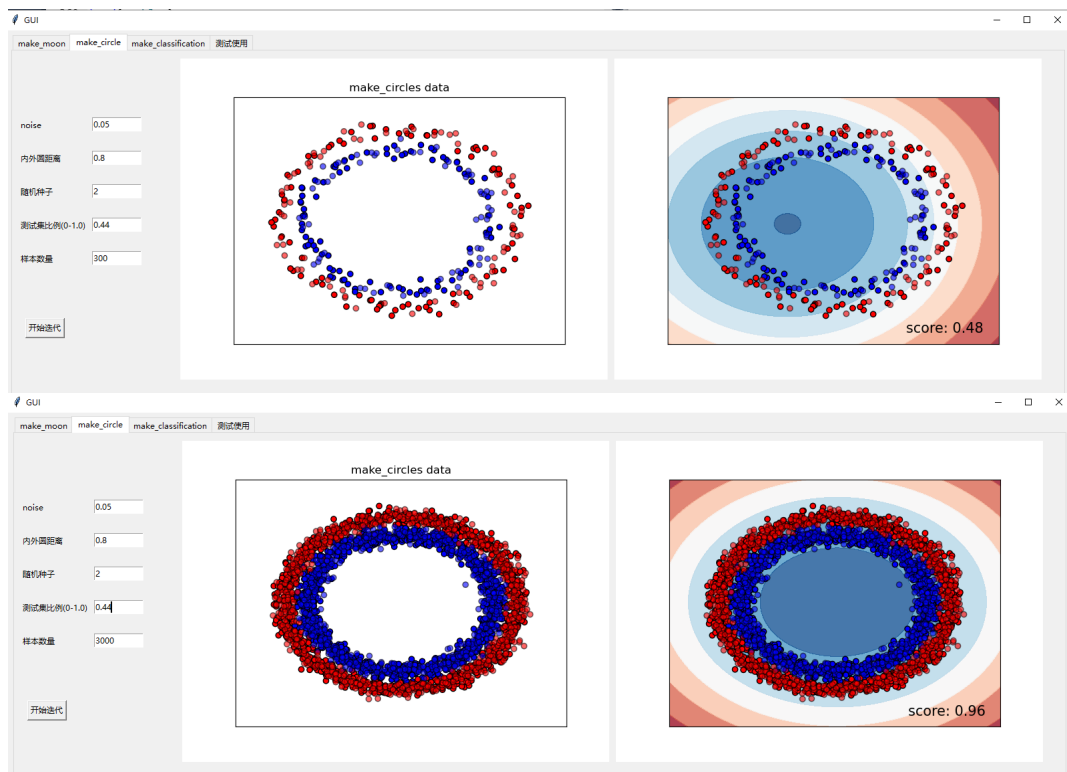


图 1: 样本太少导致过拟合

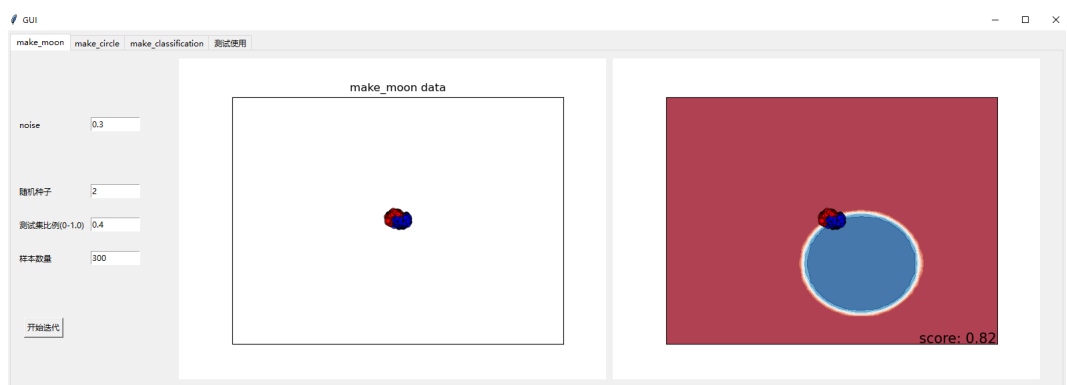


图 2: 在 make_moon 数据集观察到椭圆形决策边界

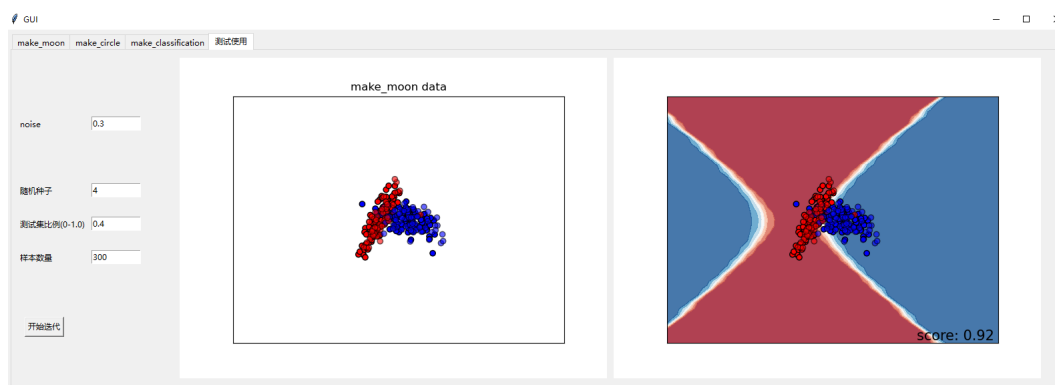


图 3: 在 `make_classification` 数据集观察到 “X” 形决策边界